Kapitel 12

WWW- World Wide Web

-

„Internet-Surfen“, „Browsen“, „Web-Surfen“

12.1 Einführung

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- Wichtigste Internet Anwendung.
- Client Server Konzept:
  - Client (Kunde): Möchte auf Informationen aus dem Internet zugreifen.
  - Server (Dienstleister): Stellt Informationen über das Internet zur Verfügung.
- Bekannte Software:
  - Client („Webbrowser“): Mozilla Firefox, Google Chrome, Microsoft Edge, Safari, Opera, …..
  - Server („Webserver“): Apache, Microsoft IIS, nginx, Google Web Server, ….
- Entstand 1989 als Projekt in CERN durch Tim Berners-Lee.

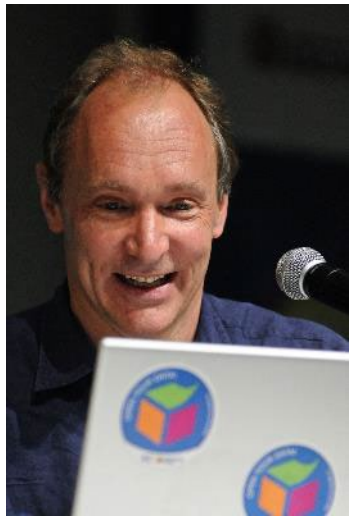

Tim Berners-Lee
Quelle: Wikipedia

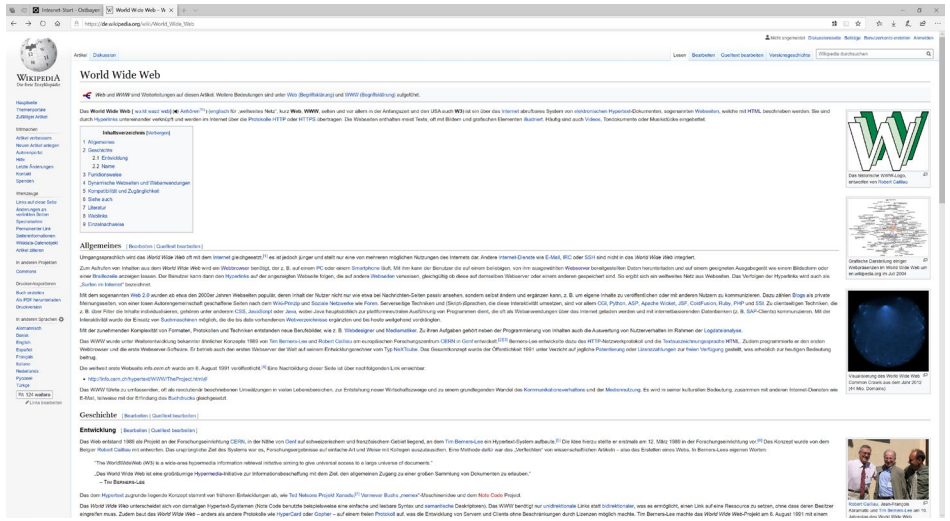

Typische Web-Seite

Quelle: Wikipedia

12.2 WWW: Grundlegende Technologien

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- Dreiklang: Drei grundlegende Standards.
  - **HTML („Hypertext Markup Language“):**
    Auszeichnungssprache – legt Inhalt, Darstellung und Verknüpfung („Hyperlinks“) zu anderen Informationen fest.
  - **URL („Uniform Ressource Locator“):**
    Bezeichnet Ort einer Ressource, die in Hyperlinks verwendet werden.
  - **HTTP („Hypertext Transfer Protocol“):**
    Zustandsloses Protokoll zur Datenübertragung auf der Anwendungsschicht.

- Grundlegende Idee:

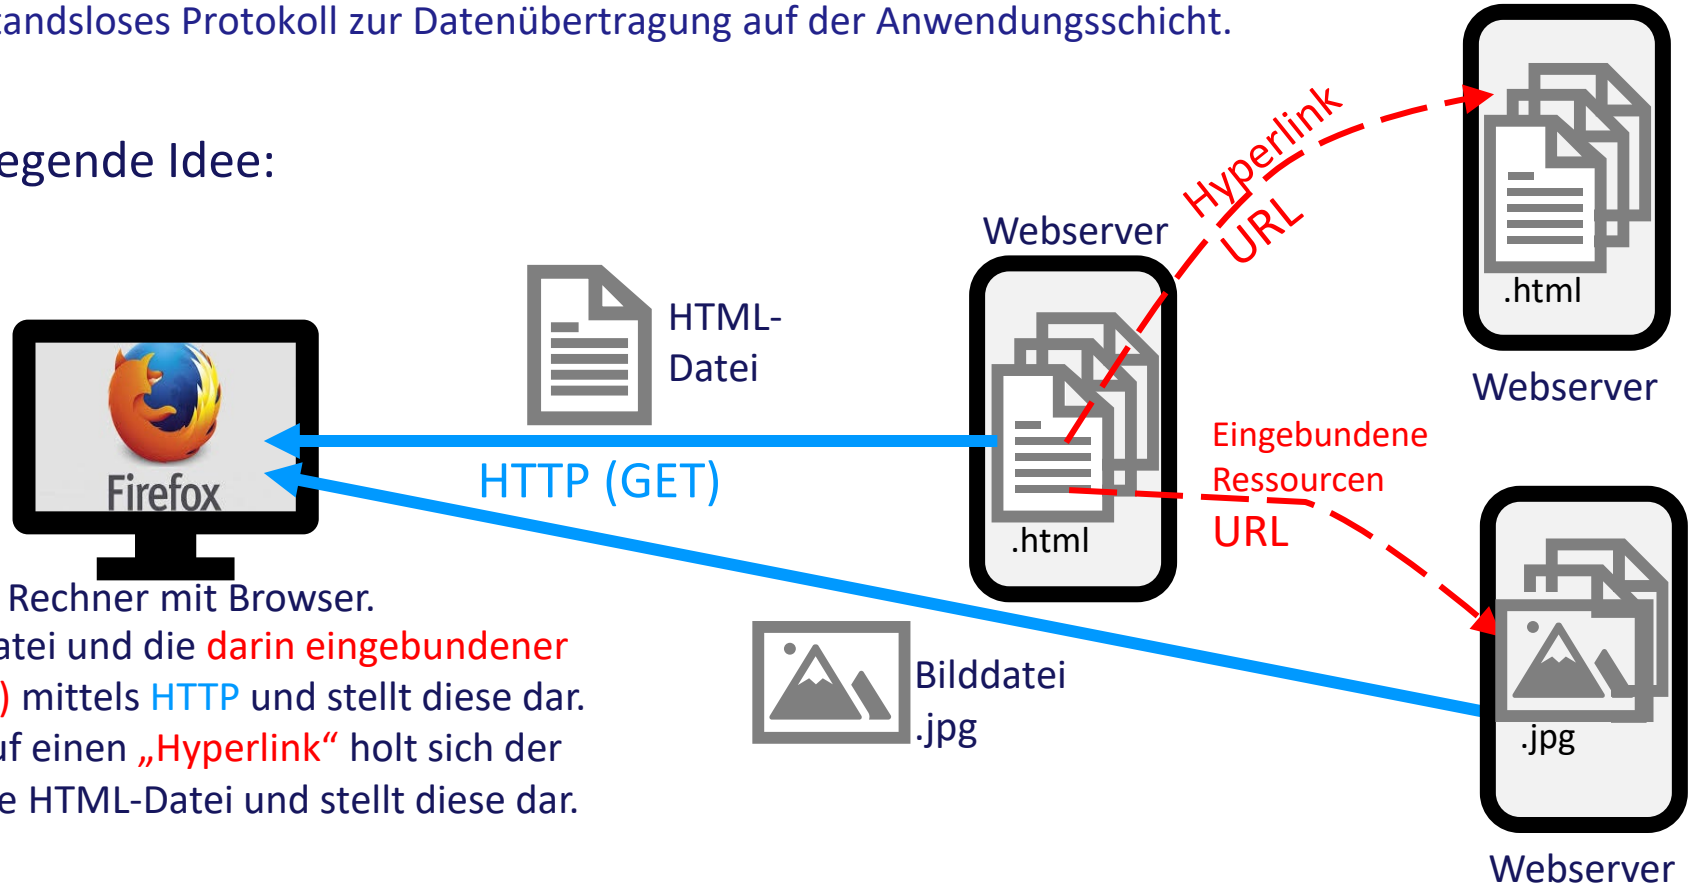

Client Rechner mit Browser.
Browser holt HTML Datei und die darin eingebundener Ressourcen (z.B. Bilder) mittels HTTP und stellt diese dar.
Klickt der Benutzer auf einen „Hyperlink“ holt sich der Browser die zugehörige HTML-Datei und stellt diese dar.

12.3 HTML

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- Textbasierte Auszeichnungsspreche für den Inhalt und tlw. Darstellung von Webseiten.
- Entwicklung durch
  - W3C (World Wise Web Consortium) und
  - WHATWG (Web Hypertext Application Technology Working Group).
- nicht Teil dieser Vorlesung, gute Dokumentation unter www.selfhtml.org.

```
<!DOCTYPE html>
<html>
<head>
<title>sample</title>
</head>
<body>
<p>Voluptatem accusantium totam rem aperiam.</p>
<img src="https://www.othr.de/logo.jpg"/>
<a href="www.othr.de">Dies ist ein Hyperlink </a>
</body>
</html>
```

HTML

Eingebundene Ressource: logo.jpg

Hyperlink

Darstellung im Browser

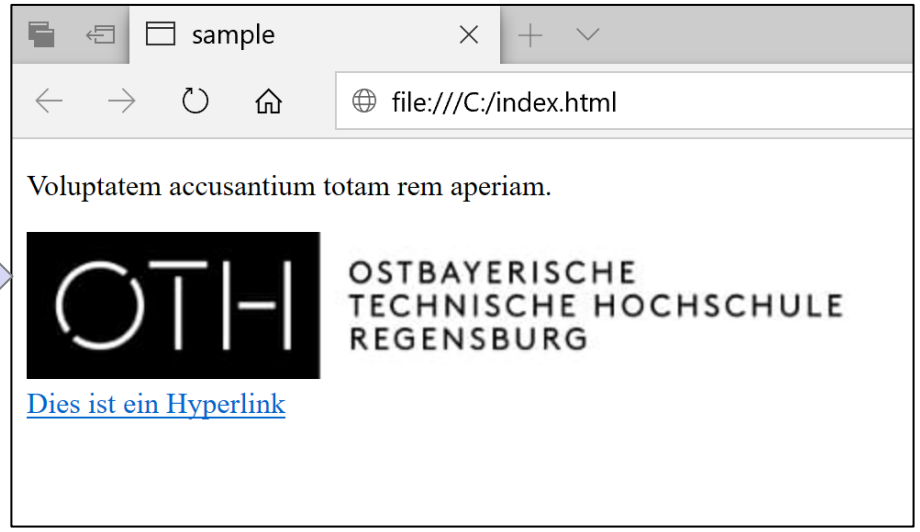

12.4 URL/URI

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- URL: spezifiziert den Ort einer Ressource.

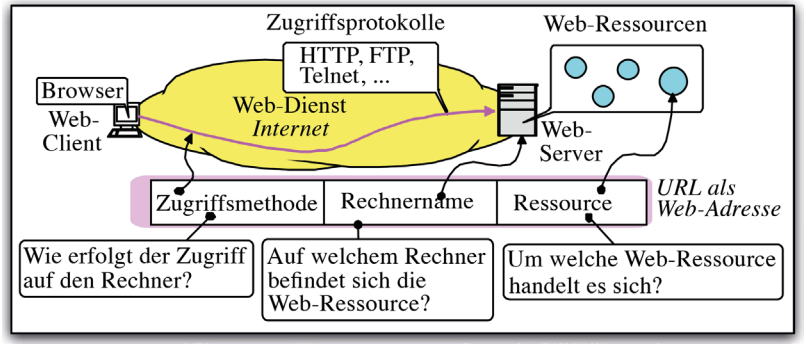

Prinzip der Adressierung beim Web-Dienst
(aus „Technik der IP-Netze“, Hanser Verlag)

- Beispiele:
  - `http://www.oth-regensburg.de/fakultät/im/willkommen.html`

    Netzwerkprotokoll/ Zugriffsmethode — Host (Name des Rechners) — Dateiname inkl. Pfad

  - `http://max:muster@www.example.com:8080/index.html?p1=A&p2=B#ressource`

    Netzwerkprotokoll/ Zugriffsmethode — Benutzer — Kennwort — Host — Port — Dateiname inkl. Pfad — Query — Fragment

Parameter	Wert
p1	A
p2	B

- RFCs: **3986**, 4248, 4266, 6068, 6196, 6270.

12.4 URL/URI

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- Unterart der URI (Uniform Ressource Indentifier): Hinweis auf den Ort einer Ressource.
- zweiteiliger Aufbau: <schema>:<schema-spezifischer-Teil>
- URL-Encoding

```
|- Schema -|- ---------------- Schema-spezifischer Teil ----------------------------------|
```

- https://de.wikipedia.org/wiki/Uniform_Resource_Identifier
- ftp://ftp.is.co.za/rfc/rfc1808.txt
- file:///C:/Users/Benutzer/Desktop/Uniform%20Resource%20Identifier.html
- file:///etc/fstab
- geo:48.33,14.122;u=22.5
- ldap://[2001:db8::7]/c=GB?objectClass?one
- gopher://gopher.floodgap.com
- mailto:John.Doe@example.com
- sip:911@pbx.mycompany.com
- news:comp.infosystems.www.servers.unix
- data:text/plain;charset=iso-8859-7,%be%fa%be
- tel:+1-816-555-1212
- telnet://192.0.2.16:80/

- Liste aller Schemas: https://www.iana.org/assignments/uri-schemes/uri-schemes.xhtml

12.4 URL/URI

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

URL/URI-Encoding

Reservierte Zeichen:

`- : / ? # [ ] @ ! $ & ' ( ) * + , ; =`

Erlaubte Zeichen:

- Buchstaben: `A-Z, a-z`
- Ziffern: `0-9`
- `- . _ ~`

Prozentdarstellung:

- Um beliebige Byte in einer URI zu übertragen müssen diese in die „Prozentdarstellung“ übertragen werden: %xx
- xx steht für den zweistelligen Hexadezimalwert des Bytes.
- Beispiele:
  - `%20`: Bytewert=32 („Leerzeichen“ im ASCII Code).
  - `%23`: Bytewert=35 („#“-Wert im ASCII Code).
  - `http://www.example.net/index.html?session=A54C6FE2%23info`

RFC 3986 empfiehlt UTF-8 Kodierung von nicht ASCII Zeichen (z.B.: „ö“ = %C3%B6).

https://www.utf8-zeichentabelle.de/unicode-utf8-table.pl?number=1024&htmlent=1

12.5 HTTP

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- Hypertext Transfer Protocol
- Übertragung von Daten aller Art zwischen Web-Browser und –Server.
  - HTML,
  - Bilder,
  - Videos,
  - Dateien,
  - Anwendungsparameter (siehe z.B. Query-Anteil in der URI),
  - ….
- Wird mittlerweile auch von anderen Anwendungen verwendet (z.B. WebDAV).
- Anwendungsprotokoll → Schicht 7.

12.5 HTTP

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- Einfache Client-Server Architektur bzw. Request/Response Struktur:

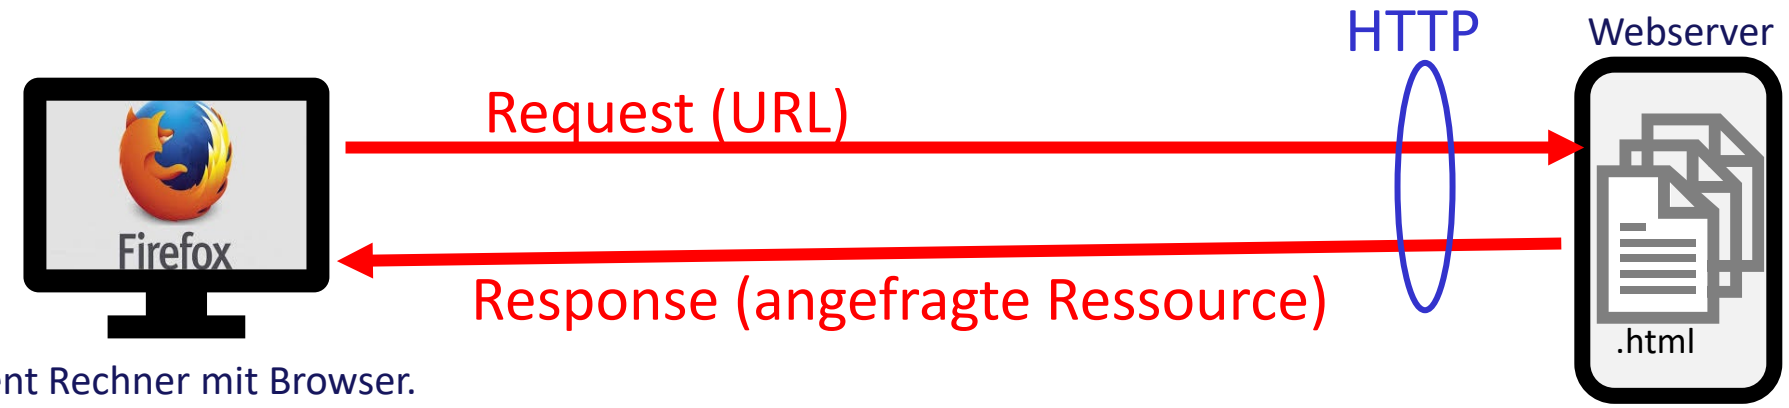

Client Rechner mit Browser.

- Zustandslos
  - Webserver kann zwei Requests nicht mithilfe von HTTP verbinden, d.h. jeder Request wird ohne Bezug zu früheren Requests behandelt.
  - Bezüge müssen über andere Mittel (z.B. durch Parameter in der URL oder Nutzdaten) hergestellt werden → Cookies etc.
- HTTP verwendet üblicherweise TCP als Transportprotokoll.
- Well-Known-Port des Servers ist 80.

12.5 HTTP

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

HTTP Versionen

- **HTTP/1.0 (RFC 1945):**
  Vor jedem Request wird TCP-Verbindung aufgebaut, nach dem Response abgebaut (7 zusätzliche Nachrichten!). Beinhaltet ein HTML-Dokument z.B. 10 Bilder auf dem gleichen Server, werden 11 TCP-Verbindungen benötigt!
- **HTTP/1.1 (RFC 2616):**
  Diverse Erweiterungen
  - Keepalive: Client möchte TCP-Verbindung für mehrere Anfragen nutzen (Server kann ablehnen)
  - Pipelining: mehrere Anfragen können über eine TCP Verbindung „parallel“ gesendet werden

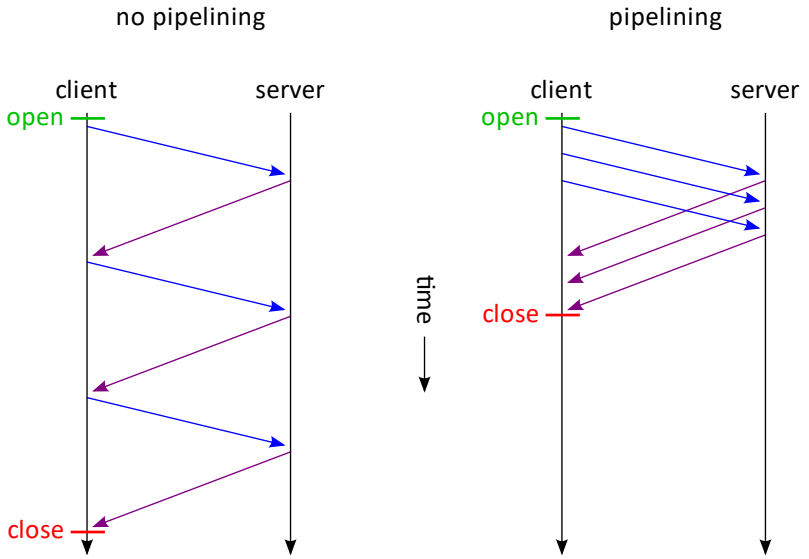

Wegen TCP Slow-Start-Algorithmus signifikante Verkürzung der Ladezeiten von Webseiten

Quelle: Wikipedia (HTTP Pipelining)

12.5 HTTP

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

HTTP Versionen

- **HTTP/2 (RFC 7540,7541): Mai 2015**
  weitere Beschleunigung und Optimierungen
  - die Möglichkeit des Zusammenfassens mehrerer Anfragen,
  - weitergehende Datenkompressionsmöglichkeiten,
  - die binär kodierte Übertragung von Inhalten und
  - Server-initiierte Datenübertragungen (push-Verfahren),
  - einzelne Streams lassen sich priorisieren.
- **HTTP/3 (RFC 9114, Juni 2022)**
  - Googles „HTTP-over-QUIC over UDP“ wird verwendet.

12.5 HTTP Request/Response

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

➢ Beispiel Request an die URL *http://www.example.net/infotext.html*:

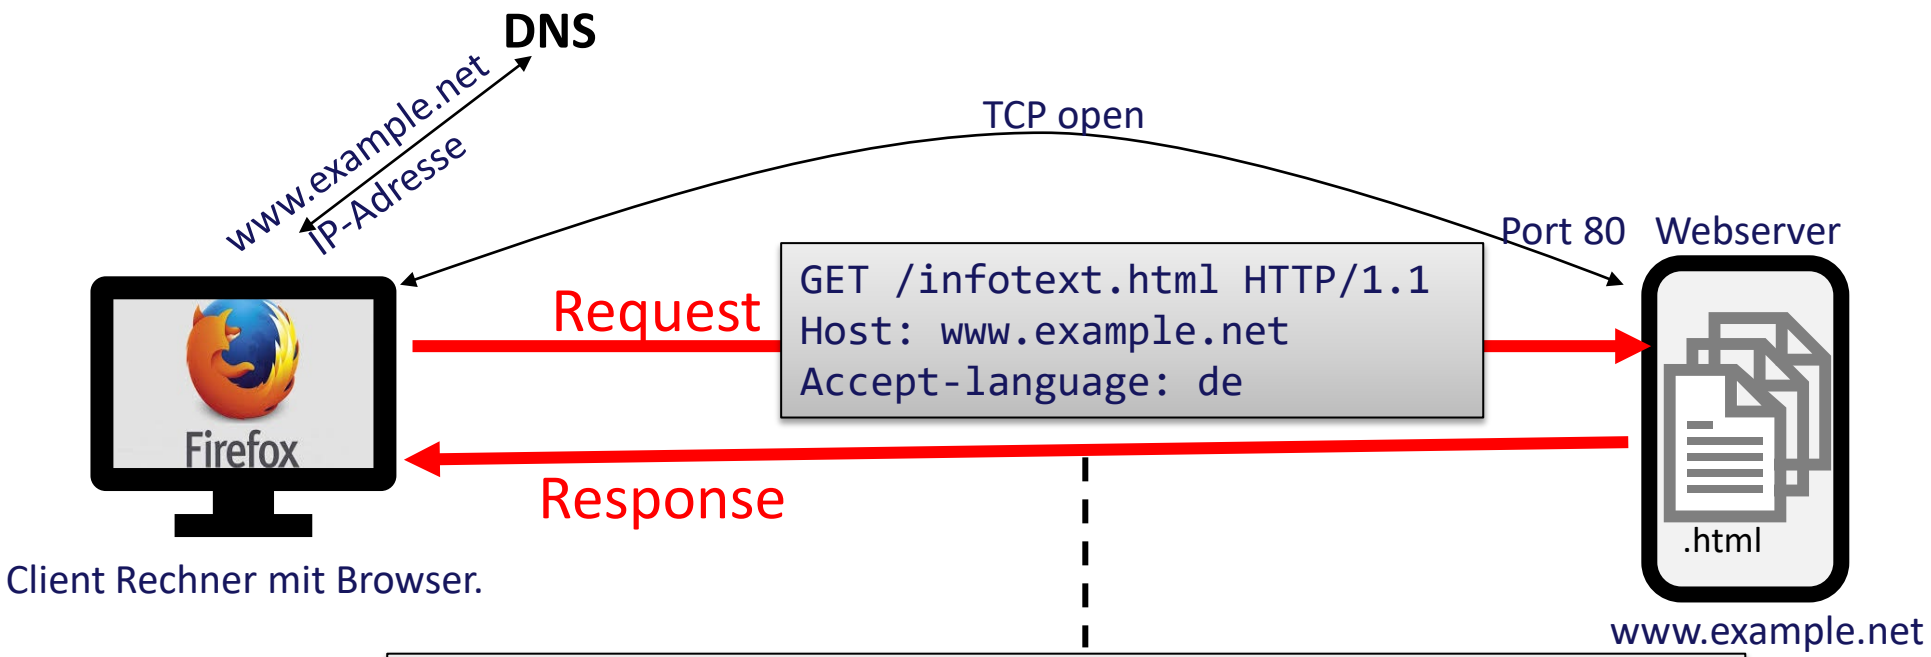


```
HTTP/1.1 200 OK
Server: Apache/1.3.29 (Unix) PHP/4.3.4
Content-Length: 123456 (Größe von infotext.html in Byte)
Last-Modified: Sun, 06 Oct 2020 09:23:24 GMT
Content-Language: de (nach RFC 3282 sowie RFC 1766)
Connection: close
Content-Type: text/html

(Inhalt von infotext.html)
```

12.5 HTTP

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

```
GET /images/logo.png HTTP/1.1
Host: www.othr.net
Accept-language: de
<CR><LF>
```

https://www.iana.org/assignments/message-headers/message-headers.xhtml#perm-headers

- Textbasiert
  - **Request**
    - Request Line (z.B. `GET /images/logo.png HTTP/1.1`).
    - Request Header Fields in der Form `key:value` (z.B. `Host: www.othr.de`).
    - Eine Leerzeile (<CR><LF> ohne Leerzeichen).
    - Optionalen Message Body („Nachrichtenrumpf“).
  - **Request Methoden** (erstes Wort der Request Line)
    - **GET**: Anforderung einer Ressource (zB Datei) unter Angabe eines URI.
    - **POST:** schickt im Nachrichtenrumpf Daten zum Server.
    - **HEAD:** wie GET, Response beinhaltet aber nur Header ohne Nachrichtenrumpf.
    - **PUT:** Hochladen einer Ressource unter Angabe des Ziel-URIs auf einen Webserver.
    - **PATCH:** Ändert ein bestehendes Dokument ohne dieses wie bei PUT vollständig zu ersetzen.
    - **DELETE:** löscht die angegebene Ressource auf dem Server.
    - **TRACE:** liefert die Anfrage so zurück, wie der Server sie empfangen hat. So kann überprüft werden, ob und wie die Anfrage auf dem Weg zum Server verändert worden ist – sinnvoll für das Debugging von Verbindungen.
    - **OPTIONS:** liefert eine Liste der vom Server unterstützten Methoden und Merkmale.
    - **CONNECT**: wird von Proxyservern implementiert, die in der Lage sind, SSL-Tunnel zur Verfügung zu stellen.

12.5 HTTP

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

```
HTTP/1.1 200 OK
Server: Apache/1.3.29 (Unix) PHP/4.3.4
Content-Length: 123456 (Größe von infotext.html
Last-Modified: Sun, 06 Oct 2020 09:23:24 GMT
Content-Language: de (nach RFC 3282 sowie RFC 17
Connection: close
Content-Type: text/html
<CR><LF>
(Inhalt von infotext.html)
```

- **Response**
  - Status Line (z.B. `HTTP/1.1 200 OK`).
  - Response Header Fields in der Form `key:value`.
  - Eine Leerzeile (<CR><LF> ohne Leerzeichen).
  - Optionalen Message Body („Nachrichtenrumpf“).
- **Status Code** (→Status Line)
  - **1xx – Informationen:** Die Bearbeitung der Anfrage dauert trotz der Rückmeldung noch an.
  - **2xx – Erfolgreiche Operation:** Die Anfrage wurde bearbeitet und die Antwort wird an den Anfragesteller zurückgesendet.
  - **3xx – Umleitung:** Gewünschte Ressource befindet sich an einem anderen Platz. Antwort enthält URI der neuen Lokation.
  - **4xx – Client-Fehler:** Fehler, der im Verantwortungsbereich des Clients liegt, z.B.:
    404: Ressource existiert nicht auf dem Server.
    403: Client hat nicht die notwendigen Rechte.
  - **5xx – Server-Fehler:** Fehler, dessen Ursache beim Server liegt, z.B.:
    501: Server verfügt nicht über die erforderlichen Funktionen, um die Anfrage zu bearbeiten.

Zusätzlich zum Statuscode enthält die Status Line eine Beschreibung des Fehlers, z.B.

HTTP/1.1 404 Not Found

12.5 HTTP Request/Response

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- Webservices, dynamische Webseiten,…:
  - statt statischer Dateien kann der Webserver auch Anwendungen ausführen
  - statt Webserver können auch andere Programme (z.B. WebDAV) HTTP benutzen

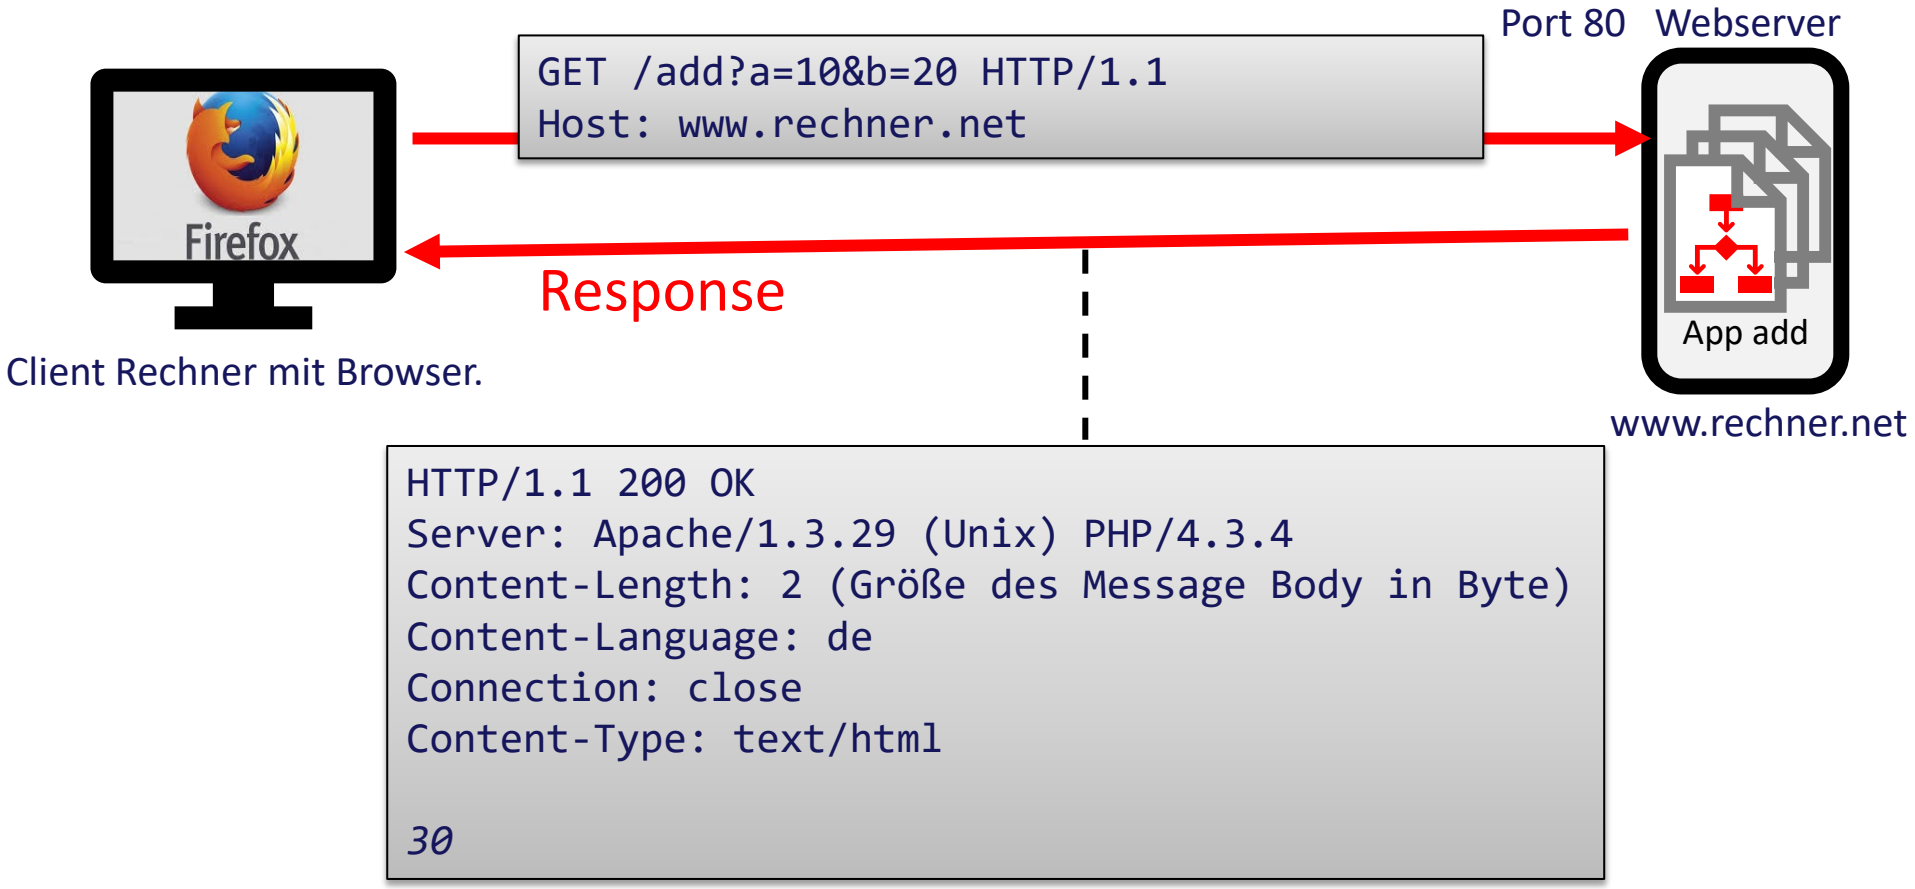

12.5 HTTP Request/Response

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

➢ Weiterleiten auf andere URI:

Beispiel Wikipedia, es wird „Katze“ im Suchfeld der Startseite eingegeben:

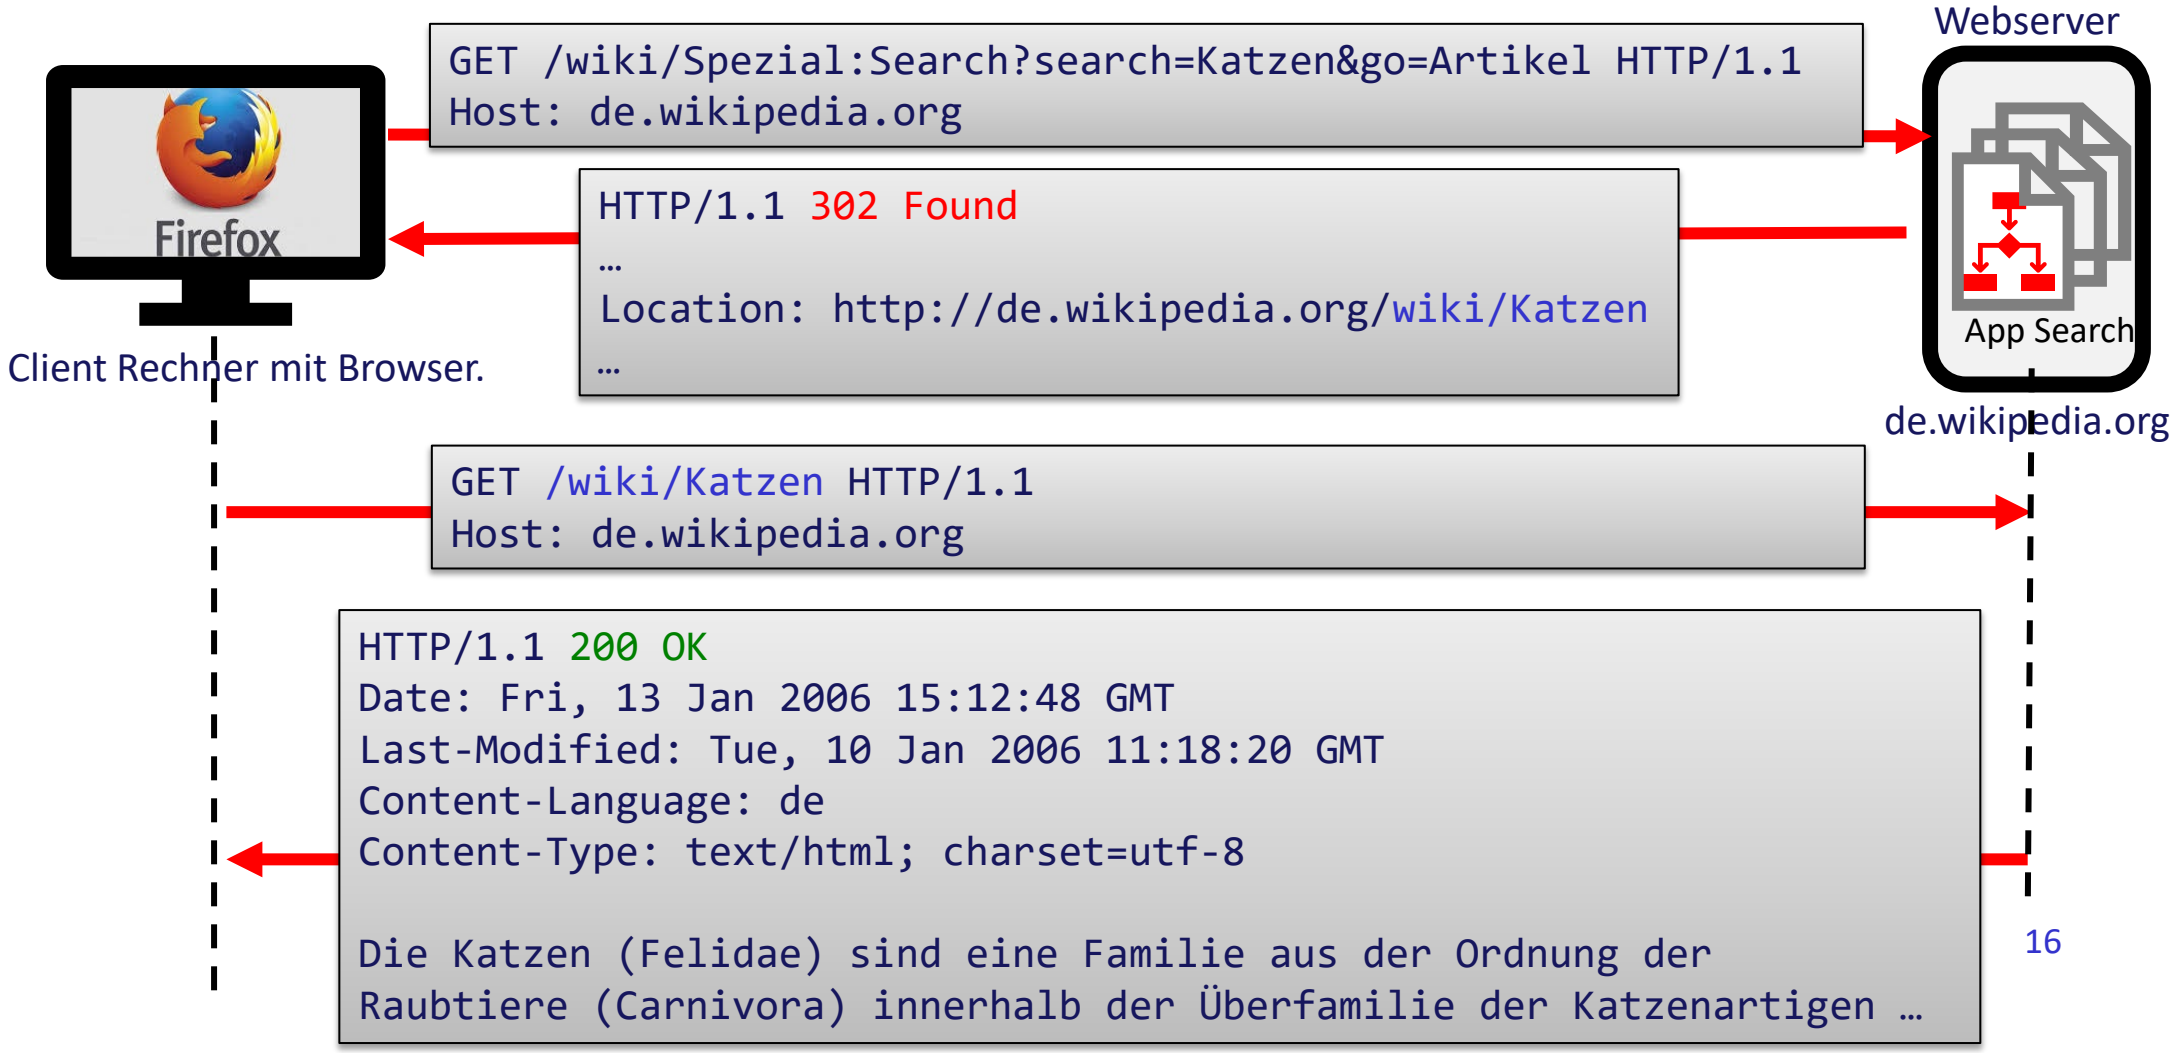

12.5 HTTP Content Type

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- Klassifiziert die Daten im Nachrichtenrumpf…
- …durch Angabe des MIME-Types (Internet Media Types)
- zwei Teile: Medientyp und Subtyp, die durch Schrägstrich getrennt sind, z.B.: `image/jpeg`
- Medientyp:
  - `application` – binäre Daten, die von einem bestimmten Programm verarbeitet werden sollen
  - `audio` – Audiodaten
  - `example` – Beispiel-Medientyp für Dokumentationen
  - `image` – für Grafiken
  - `message` – für Nachrichten, z.B. message/rfc822
  - `model` – mehrdimensionale Datenstrukturen
  - `multipart` – mehrteilige Nachrichten
  - `text` – für Text
  - `video` – für Videomaterial
- mehr als 130 Subtypen: https://www.iana.org/assignments/media-types/media-types.xhtml

12.6 Synthese: Ein Tag im Leben eines Web-Requests

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

- journey down protocol stack complete!
  - application, transport, network, link
- putting-it-all-together: synthesis!
  - *goal:* identify, review, understand protocols (at all layers) involved in seemingly simple scenario: requesting www page
  - *scenario:* student attaches laptop to campus network, requests/receives www.google.com

12.6 Synthese: Ein Tag im Leben…

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

➢ Szenario

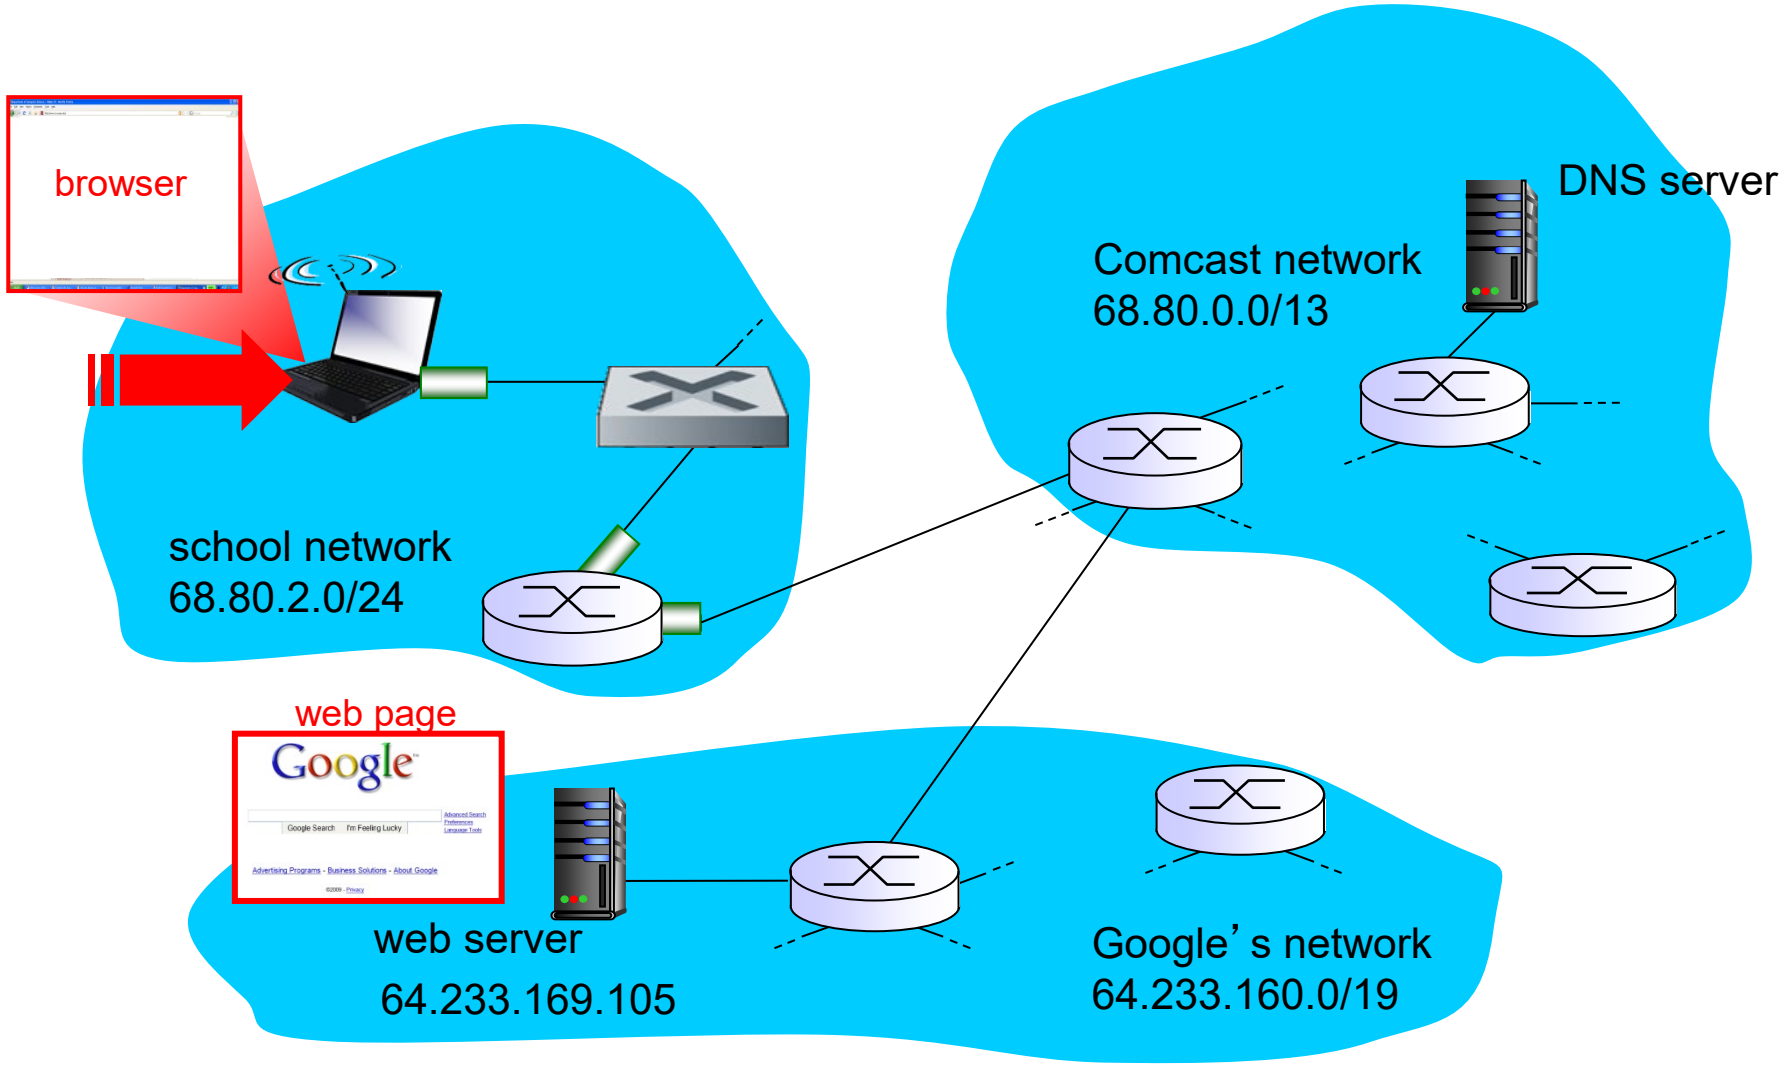

Aus: Computernetzwerke von Kurose und Ross

12.6 Synthese: Ein Tag im Leben…

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

➢ Verbinden mit dem Internet

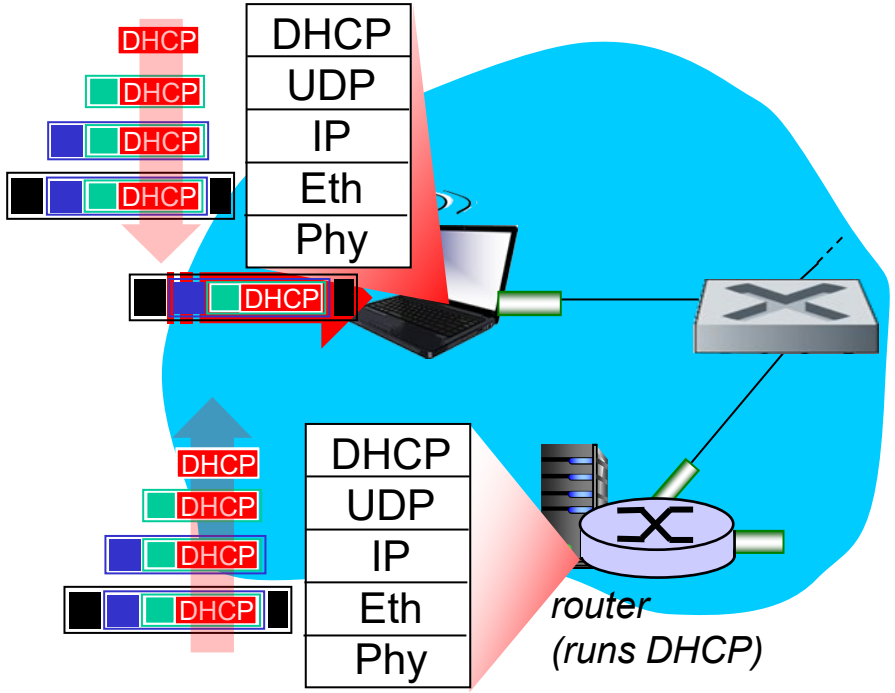

➢ connecting laptop needs to get its own IP address, addr of first-hop router, addr of DNS server: use *DHCP*

- DHCP request encapsulated in UDP, encapsulated in IP, encapsulated in 802.3 Ethernet
- Ethernet frame broadcast (dest: FFFFFFFFFFFF) on LAN, received at router running DHCP server

Aus: Computernetzwerke von Kurose und Ross

12.6 Synthese: Ein Tag im Leben…

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

➢ Verbinden mit dem Internet

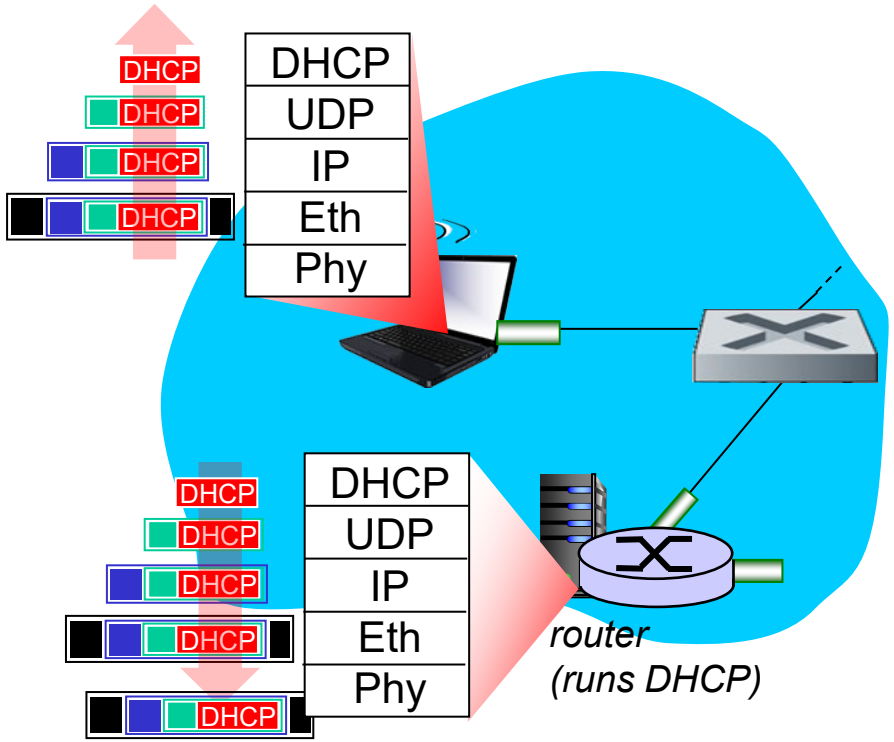

- ➢ DHCP server formulates *DHCP ACK* containing client's IP address, IP address of first-hop router for client, name & IP address of DNS server
- encapsulation at DHCP server, frame forwarded (switch learning) through LAN, demultiplexing at client
- DHCP client receives DHCP ACK reply

Client now has IP address, knows name & addr of DNS server, IP address of its first-hop router

Aus: Computernetzwerke von Kurose und Ross

12.6 Synthese: Ein Tag im Leben…

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

➢ ARP (vor DNS, vor HTTP)

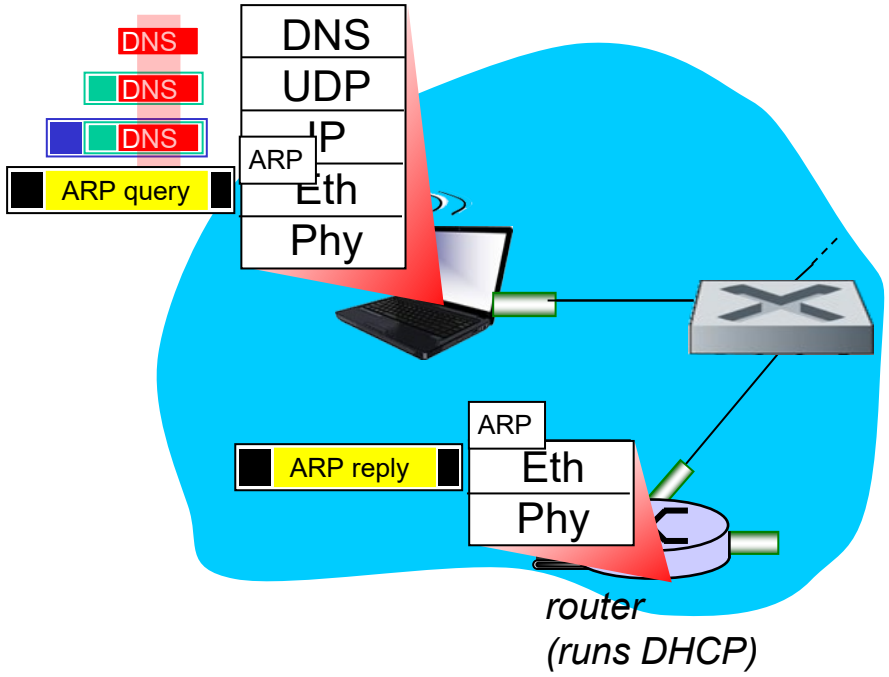

- before sending *HTTP* request, need IP address of www.google.com: *DNS*
- DNS query created, encapsulated in UDP, encapsulated in IP, encapsulated in Eth. To send frame to router, need MAC address of router interface: ARP
- ARP query broadcast, received by router, which replies with ARP reply giving MAC address of router interface
- client now knows MAC address of first hop router, so can now send frame containing DNS query

Aus: Computernetzwerke von Kurose und Ross

12.6 Synthese: Ein Tag im Leben…

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

➢ DNS Auflösung

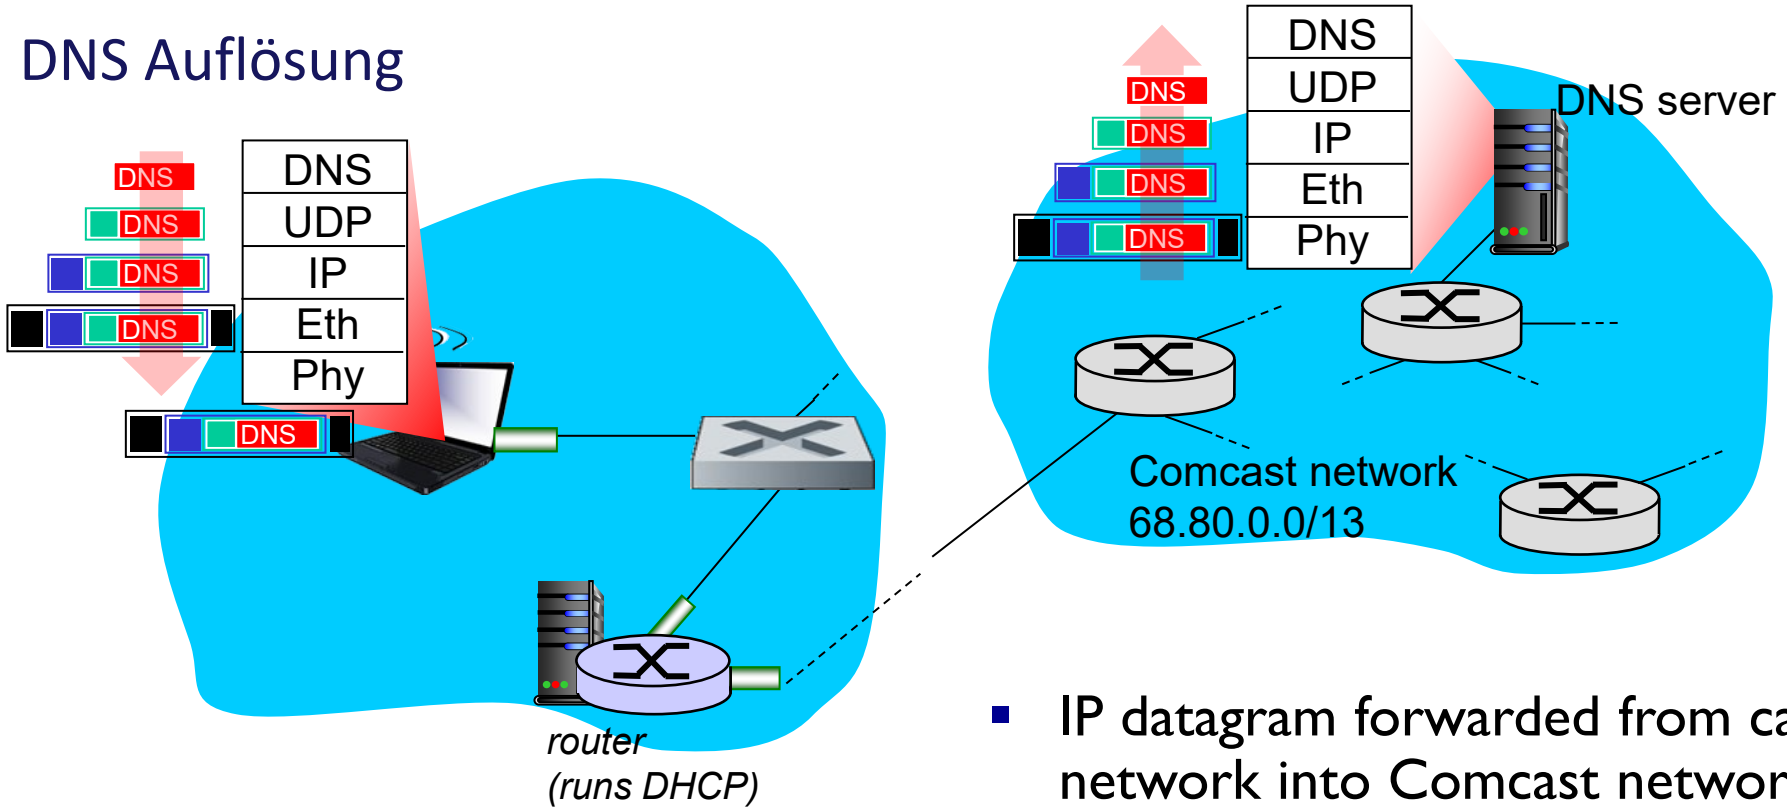

- IP datagram containing DNS query forwarded via LAN switch from client to 1st hop router

- IP datagram forwarded from campus network into Comcast network, routed (tables created by RIP, OSPF, IS-IS and/or BGP routing protocols) to DNS server
- demuxed to DNS server
- DNS server replies to client with IP address of www.google.com

Aus: Computernetzwerke von Kurose und Ross

12.6 Synthese: Ein Tag im Leben…

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

➢ TCP Verbindung für HTTP Transport

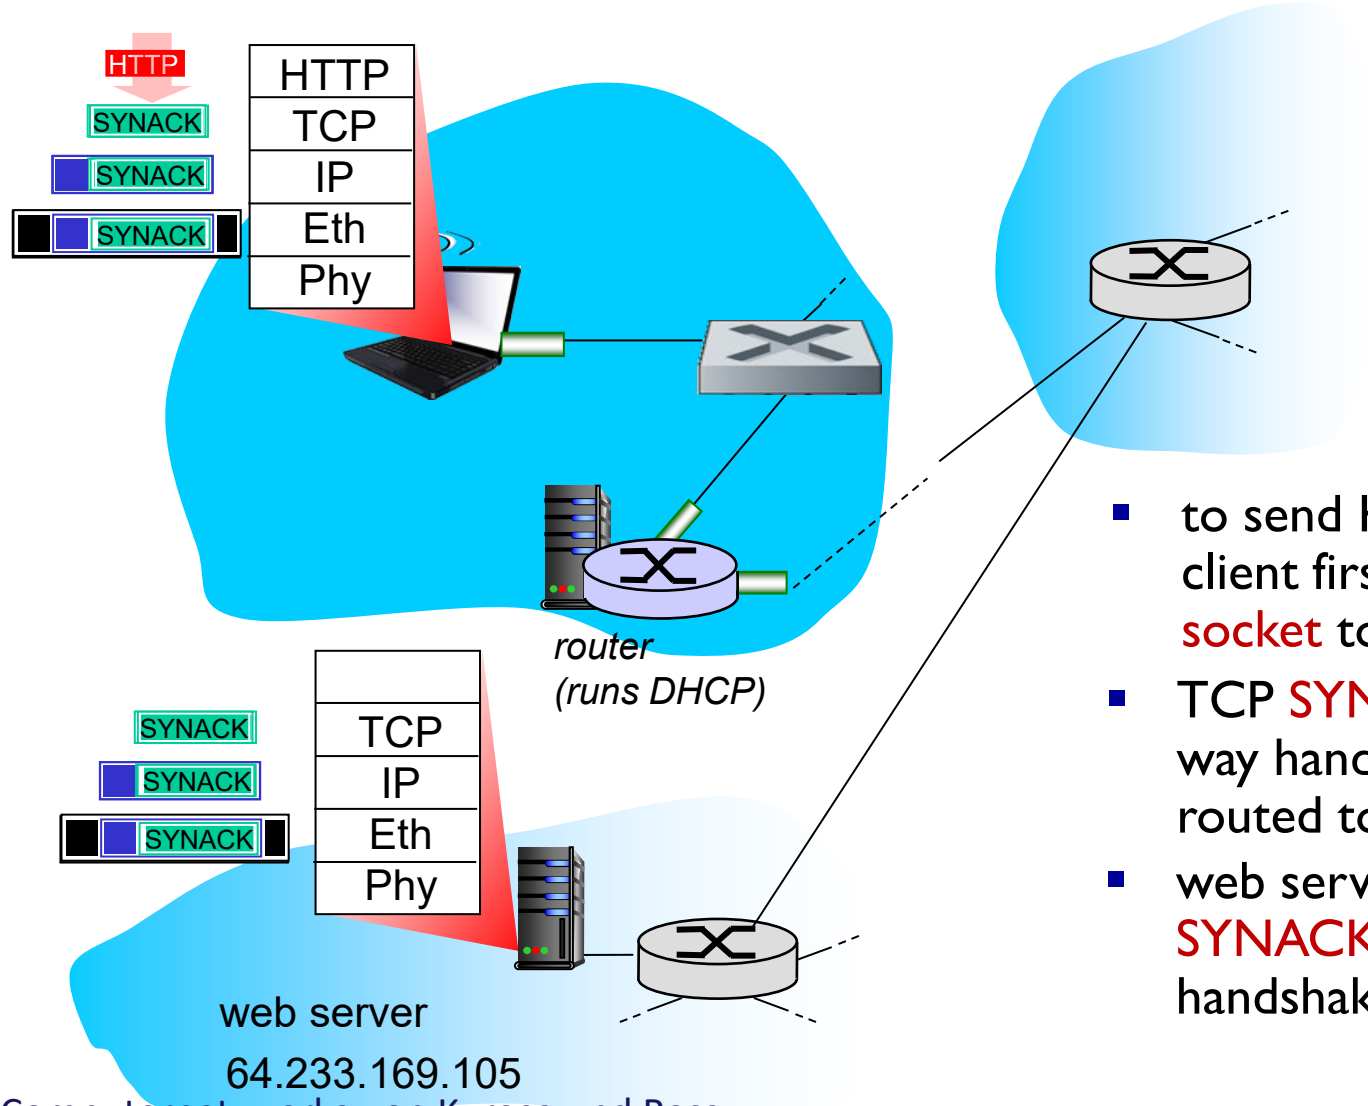

- to send HTTP request, client first opens TCP socket to web server
- TCP SYN segment (step 1 in 3-way handshake) inter-domain routed to web server
- web server responds with TCP SYNACK (step 2 in 3-way handshake)

Aus: Computernetzwerke von Kurose und Ross

12.6 Synthese: Ein Tag im Leben…

Inhalt

- Grundlagen
- Pakete, Rahmen, Fehlererkennung
- LAN-Technologien
- Routingprotokolle
- IP-Adresse
- IP
- UDP
- TCP
- DNS
- DHCP
- **WWW**

➢ HTTP request/reply

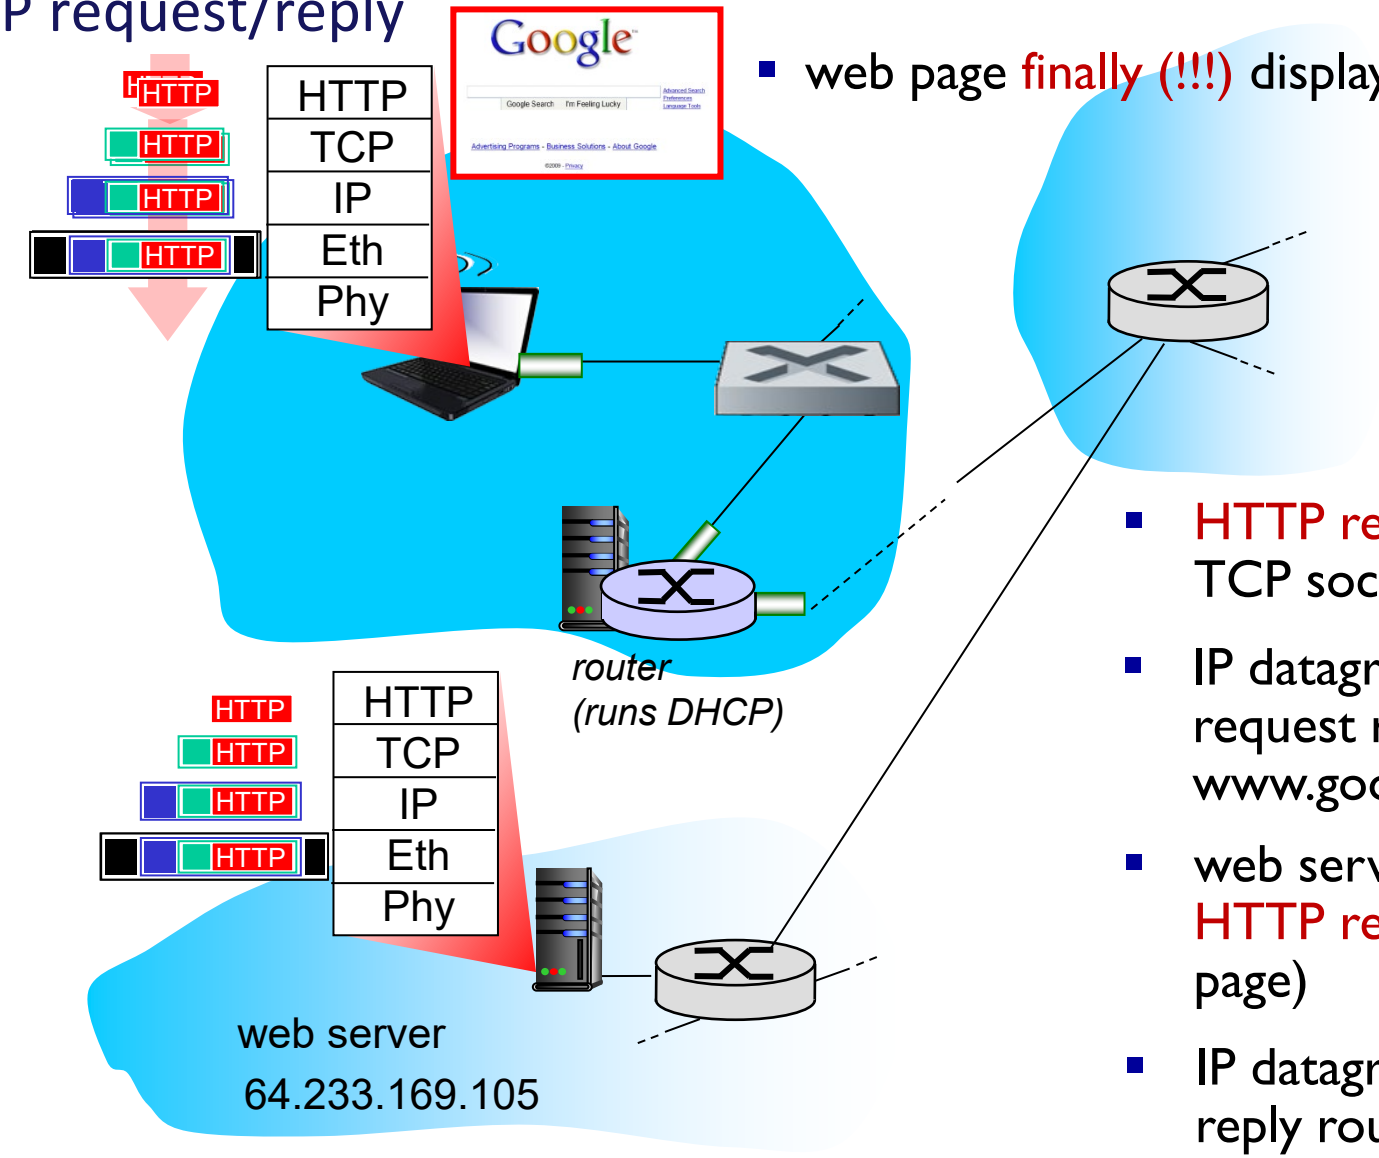

- web page finally (!!!) displayed

- HTTP request sent into TCP socket
- IP datagram containing HTTP request routed to www.google.com
- web server responds with HTTP reply (containing web page)
- IP datagram containing HTTP reply routed back to client

Aus: Computernetzwerke von Kurose und Ross